

Raport

California Housing Prices - RandomForestRegressor

Cuprins:

1. Introducere: Motivație, descriere generală temă, tip de algoritm și algoritm ales.
2. Metodologie: Descriere implementare și particularități algoritm
3. Rezultate obținute: Rezultate explicate obținute la antrenare, validare și testare. Trebuie să conțină Matricea de Confuzie explicată și indicatori de performanță
4. Concluzii: Concluzii proprii desprinse din lucrarea efectuată și comentate pe baza rezultatelor obținute.

1. Introducere:

Scopul proiectului este de a antrena un algoritm care să prezică prețul casei în sute de mii de dolari.

Am ales biblioteca **california_housing()** care conține următoarele date:

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	MedHouseVal
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	-122.23	4.526
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	-122.22	3.585
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37.85	-122.24	3.521
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37.85	-122.25	3.413
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37.85	-122.25	3.422


```
#încărcăm setul de date
data = fetch_california_housing(as_frame=True)
print(data.frame.head())
```

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	MedHouseVal
0	8.3252	41.0	6.984127	1.023810	322.0	2.555556	37.88	-122.23	4.526
1	8.3014	21.0	6.238137	0.971880	2401.0	2.109842	37.86	-122.22	3.585
2	7.2574	52.0	8.288136	1.073446	496.0	2.802260	37.85	-122.24	3.521
3	5.6431	52.0	5.817352	1.073059	558.0	2.547945	37.85	-122.25	3.413
4	3.8462	52.0	6.281853	1.081081	565.0	2.181467	37.85	-122.25	3.422

Link-ul pentru setul de date: [The California housing dataset — Scikit-learn course](#)

Predicția se face în funcție de ultima coloană, **MedHouseVal**.

În acest set de date avem informații despre demografie (venituri, populație, ocupația casei) în sectoare/ cartiere, locația cartierului (latitudine, longitudine) și informații generale legate de cartierul în care se află casa (numărul de camere, numărul de dormitoare, vârsta casei).

2. Metodologie:

Setul de date a fost împărțit în 80% pentru antrenare și 20% pentru testare.

Am folosit algoritmul RandomForestRegressor.

Random Forest Regression este un algoritm de învățare automată bazat pe tehnica de ensemble learning, utilizat pentru rezolvarea problemelor de regresie. Este o extensie a algoritmului Random Forest aplicată pentru predicția valorilor numerice continue.

n_estimators este folosit pentru specificitatea algoritmului. Valoare default a acestui hiperparametru pentru algoritmul RandomForestRegressor este 100.

Random state este folosit pentru reproductibilitate. Se alege un punct arbitrar de început, în cazul nostru 42, pentru a obține același rezultat ori de câte ori codul este rulat.

Indicatori de performanță sunt următorii și reprezintă:

MSE – număr de erori cu diferențe foarte mari, dacă ai multe ai MSE valoare mare


MAE – număr de erori, nu contează dacă sunt mari sau mici

R2 - cât de bine se potrivește modelul pe datele noastre

RMSE – e undeva între MSE și MAE


3. Rezultate algoritm:

RandomForestRegression




Pentru a vizualiza rezultatele am realizat graficul între valorile prezise și cele adevărate. Pe linia roșie sunt valorile adevărate și se poate observa că sunt și valori apropiate de linie și valori mai depărtate de linie. Acest lucru se întâmplă pentru că setul de date conține mai mulți parametri după care se ia (coloanele setului de date: MedInc, HouseAge, AveRooms, Population, AveOccup, Latitude, Longitude, MedHouseVal).

Graficul este:




Am comparat valorile și pentru fiecare coloană, pentru fiecare parametru ca în exemplul de mai jos:



Am încercat să fac și cu algoritmul de regresie liniară, iar rezultatele indicilor de predicție au fost mai proaste:

```
➡ Performance on Training Set:  
- MSE: 0.5179331255246699  
- MAE: 0.5286283596582376  
- R2 Score: 0.6125511913966952  
- RMSE Score: 0.7196757085831575  
  
Performance on Test Set:  
- MSE: 0.5558915986952422  
- MAE: 0.533200130495698  
- R2 Score: 0.5757877060324524  
- RMSE Score: 0.7455813830127749
```

Însă graficul pare mai aproape de linia roșie, de valorile de adevăr, decât graficul de la RandomForestRegression.



4. Concluzii:

Algoritmul RandomForestRegressor este mai eficient pentru setul meu de date decât algoritmul de Regresie Liniară.

Scorul R^2 este mai mic în setul de test decât în setul de antrenare ceea ce înseamnă că modelul trece prin overtraining, adică s-a obișnuit cu datele de antrenare, iar la datele de test, algoritmul nu mai gândește, ci dă un rezultat baza pe ceea ce s-a obișnuit.

Am încercat să pun $n_{\text{estimators}}$ și 50 și 200, iar rezultatul nu se modifică, ceea ce înseamnă că pentru setul de date dat atât se poate obține maxim performanța.

Pentru setul meu de date, scorurile RMSE, MSE și MAE au toate valori foarte mici (am erori reduse), ceea ce înseamnă că modelul are o performanță bună (fapt vizibil din scorul R^2 , aproape perfect).